

SISTEMA PROFISSIONAL DE ORÇAMENTAÇÃO FARMACÊUTICA COM RAG

*Arquitetura Corporativa, Tratamento de Erros por Domínios e Ingestão Híbrida
no n8n*

INTEGRANTES DO GRUPO:

Eduardo Peruzzo
Estevão Moraes
Marcelle Lohane
Gabriel Corrêa
Mateus Sachinho

Disciplina: Extração e Preparação de Dados
Avaliação: AP2
Professor: Alvaro Riz Barros

1. Introdução e Contexto do Sistema

Este documento apresenta a documentação técnica e de engenharia de dados do Sistema Profissional de Orçamentação Corporativa desenvolvido para a avaliação da AP2 na disciplina de Extração e Preparação de Dados. O objetivo central do projeto consiste em estender um protótipo básico de RAG (Retrieval-Augmented Generation) e transformá-lo em uma solução robusta e resiliente de nível de produção, aderente às melhores práticas de mercado.

A solução é construída sobre a infraestrutura do n8n, operando de forma integrada a um banco de dados vetorial Qdrant e modelos avançados de inteligência artificial via OpenRouter. O pipeline resolve com precisão desafios críticos corporativos, tais como: a interpretação de requisições de clientes em linguagem natural altamente informal, a identificação determinística e probabilística de produtos, a aplicação correta e dinâmica de alíquotas de ICMS estaduais conforme a natureza jurídica do comprador (PF/PJ), e o tratamento rigoroso de exceções através de um isolamento por domínios.

2. Arquitetura Geral da Solução (Pipeline de Consulta)

O fluxo de consulta foi arquitetado sob o modelo orientado a eventos, sendo exposto através de um Webhook corporativo que aceita requisições via método HTTP POST no endpoint /orcamento. A resposta ao cliente é síncrona e estruturada, utilizando o nó Respond to Webhook para garantir a entrega de um JSON padronizado e limpo.

O fluxo de dados segue uma esteira linear dividida em cinco macroetapas:

- **1. Recepção e Higieneização de Entrada:** O nó Webhook captura o payload e o sanitiza por meio de um nó de código JavaScript, extraindo e validando o campo obrigatório 'solicitacao'.
- **2. Extração de Entidades via LLM (Agente 1):** Um agente inteligente alimentado pelo modelo Gemma-4-31b-it via OpenRouter interpreta o texto livre do e-mail do cliente, estruturando um JSON intermediário contendo o estado (UF, caso não informado considera SP), tipo de cliente (PF/PJ, caso não informado considera pessoa física, pmc) e uma lista isolada contendo apenas termos de produtos ou códigos numéricos.
- **3. Roteamento Híbrido de Busca (Data Retrieval):** Uma estrutura condicional avalia se a lista extraída contém códigos SAP (numéricos puros) ou descrições textuais. Requisições de códigos SAP acionam uma busca exata via API Scroll do Qdrant. Descrições textuais acionam o embedding da HuggingFace e realizam a busca por similaridade de cosseno no banco vetorial.
- **4. Alinhamento Fiscal e Seleção de Preços:** Um motor de regras em JavaScript consolida as respostas, remove duplicidades, avalia os scores de confiança (MÁXIMA, ALTA, MÉDIA, BAIXA) e mapeia dinamicamente os preços corretos baseados na UF do cliente e no enquadramento comercial (Preço de Fábrica - PF ou Preço Máximo ao Consumidor - PMC).
- **5. Consolidação e Resposta (Agente 2):** Um segundo agente LLM recebe o e-mail original e o catálogo restrito e filtrado de preços da etapa anterior. Sua função é calcular as

quantidades corretas, descartar itens irrelevantes que vieram do banco vetorial como ruído e gerar o JSON definitivo com as observações legais adequadas.

3. Estratégia de Ingestão de Dados e Chunking Semântico

Para que o sistema de busca vetorial funcione com precisão milimétrica, o fluxo de ingestão foi desenhado para processar a base de dados oficial (Catalogo-Produtos.csv) convertendo registros tabulares em documentos altamente semânticos.

Em vez de utilizar uma divisão por janelas de caracteres ou Token Splitter cru na base inteira (o que fragmentaria as informações cruciais de um medicamento), a solução adota uma estratégia de Chunking Semântico Customizado por Código. O fluxo lê o arquivo CSV e duplica o mapeamento de busca em dois fluxos paralelos que se fundem posteriormente:

- **Chunk Semântico por Apresentação/Nome:** O conteúdo principal do texto enviado para a geração de embeddings é preenchido unicamente com a string da coluna 'APRESENTAÇÃO'. Isso garante que buscas por nomes comerciais ou apresentações específicas encontrem correspondência exata no espaço vetorial.
- **Chunk Semântico por Princípio Ativo:** Em paralelo, é gerado um segundo documento onde o conteúdo semântico é preenchido estritamente com o 'PRINCIPIO ATIVO'. Isso permite que e-mails informais que mencionam apenas a substância química (ex: 'acetilcisteína') sejam recuperados com altíssimo score de similaridade, mesmo que o nome comercial seja diferente.

Metadados Enriquecidos: Para cada item ingerido, todos os dados estruturados e fiscais são encapsulados no dicionário de metadados do ponto do Qdrant. Isso inclui o código SAP, EAN, Registro MS, Família, Tarja, e o mapa completo de preços indexados por alíquota de ICMS (ICMS 0%, 12%, 17%, 17.5%, 18%, 20%, além de variações regionais como AC/RR, RO, AM/AP). Isso viabiliza que, uma vez localizado o vetor, todas as regras de negócio sejam executadas localmente com latência zero e sem novas chamadas de IA.

4. Configuração do Banco Vetorial e Embeddings

O armazenamento e a indexação dos vetores foram implementados utilizando o banco de dados vetorial Qdrant, hospedado em ambiente Cloud de produção. As configurações fundamentais adotadas no pipeline de engenharia são:

Parâmetro de Engenharia	Configuração Implementada
Modelo de Embeddings	HuggingFace Inference API - sentence-transformers/all-MiniLM-L6-v2
Dimensão Vetorial	384 dimensões (tamanho nativo e otimizado do modelo L6-v2)
Métrica de Distância	Similaridade de Cosseno (Cosine Distance), ideal para correspondência textual farmacêutica
Indexação de Chave (SAP)	Criação de um índice do tipo 'keyword' no campo 'metadata.sap' via API do Qdrant

5. Modelos de Linguagem Utilizados e Justificativa Técnica

O coração cognitivo do pipeline é alimentado pelo modelo google/gemma-4-31b-it, acessado remotamente por meio da API unificada do OpenRouter. A seleção desse arranjo tecnológico baseia-se em critérios técnicos rigorosos de engenharia e regras estabelecidas para o projeto:

- **Atendimento aos Critérios de Custo Zero:** O modelo selecionado está disponível na camada gratuita (free tier) do OpenRouter, cumprindo integralmente o requisito de gratuidade imposto para o desenvolvimento acadêmico, sem abrir mão de alta capacidade computacional.
- **Aderência à Linguagem e Instruções de Sistema:** O Gemma demonstrou excelente aderência a instruções complexas do sistema (System Messages), garantindo que as saídas dos agentes fossem entregues em formato JSON puro, sem a inclusão de blocos de marcação Markdown (``json) ou explicações textuais que quebrariam o parser automatizado.
- **Isolamento e Modularidade de Componentes:** A arquitetura foi concebida de forma agnóstica em relação à IA generativa. O modelo de texto (Gemma) pode ser facilmente substituído nas configurações dos nós de chat caso haja alteração de cotas. Contudo, a documentação enfatiza que o modelo de Embeddings (HuggingFace L6-v2) deve ser alterado com extrema cautela, uma vez que o tamanho do vetor gerado (384) está estritamente acoplado à dimensão física configurada na coleção do Qdrant. Qualquer alteração no modelo de embeddings exigiria a reconfiguração estrutural do banco e a reingestão integral dos chunks da base de dados.

6. Estratégia de Tratamento de Erros e Resiliência (Stop and Error)

Em conformidade com as diretrizes de nível de produção exigidas no edital, o sistema rejeita respostas nulas ou comportamentos inesperados (silent failures). Foi estruturada uma malha fina de captura de exceções baseada na técnica de Stop and Error do n8n, segmentando a aplicação em quatro domínios independentes de auditoria:

- **Domínio 1: Validação de Entrada (Erro Entrada):** Captura payloads malformados, ausência do campo de solicitação ou parâmetros vazios, devolvendo status 500 imediatamente antes de consumir tokens de IA.
- **Domínio 2: Extração de Entidades (Erro Extração LLM):** Monitora timeouts, estouros de limite de requisições (rate limits) do OpenRouter e, crucialmente, intercepta se a IA retornar um formato estrutural inválido ou uma lista vazia de itens, forçando a rota de erro.
- **Domínio 3: Infraestrutura e Recuperação (Erro Busca Vetorial):** Captura quedas de conexão com a Cloud do Qdrant ou indisponibilidade pontual na API de inferência de embeddings da HuggingFace.
- **Domínio 4: Regras de Negócio e Consolidação (Erro Geração):** Valida inconsistências lógico-fiscais no cálculo matemático do orçamento final, problemas no mapeamento de strings ou falhas na conversão monetária.

Filosofia de Dupla Camada na Resposta: Cada nó de tratamento de erro executa uma lógica em JavaScript que cria duas saídas distintas e simultâneas. A primeira é uma mensagem amigável e segura enviada de volta ao cliente da API através do Webhook, exibindo um JSON com status 500 e a justificativa no campo 'obs'. A segunda é um objeto de metadados internos rico em detalhes técnicos (contendo o nome do nó exato que falhou, o grupo de domínio e o stacktrace do erro), o qual é injetado no nó Stop and Error. Isso permite que o administrador do sistema audite a falha instantaneamente pelo painel do n8n sem expor dados sensíveis da infraestrutura para o usuário externo.

7. Generalização da API e Diferenciais de Engenharia

O sistema cumpre com rigor o critério de generalização. Nenhuma regra de negócio ou mapeamento de string foi hardcoded para a base de dados atual. Caso a banca examinadora realize o upload de um CSV completamente modificado, contendo novos fármacos, dosagens e valores, o pipeline realizará a reindexação automática e continuará operando perfeitamente. O único critério é manter a mesma estrutura de colunas do CSV base.

Como diferenciais competitivos de engenharia implementados, destacam-se:

- **Busca Híbrida:** O pipeline não depende exclusivamente de buscas semânticas (que podem apresentar alucinações em códigos numéricos). Ele implementa uma ramificação dupla de busca: códigos SAP são buscados de forma exata e determinística através da API

Scroll indexada do Qdrant, enquanto nomes e princípios ativos entram na esteira de embeddings vetoriais.

- **Tratamento de Ambiguidade de Produtos (Status 422):** Se o cliente solicitar um composto de forma genérica (ex: 'ACEBROFILINA') e o banco retornar múltiplas apresentações incompatíveis (como xarope infantil 25mg e xarope adulto 50mg), o sistema não escolhe aleatoriamente. O Agente 2 identifica a colisão, limpa a lista de itens e retorna um status HTTP 422 instruindo o cliente a especificar o produto desejado.
- **Tratamento de Itens Fora da Base (Status 404):** Pedidos de produtos completamente alheios ao escopo da base de dados (ex: 'miojo') passam pela busca vetorial, são filtrados abaixo do threshold de score mínimo (0.40) no nó de tratamento, ou filtrados pelo próprio agente de orçamentação, e disparam uma resposta limpa com status HTTP 404 de produto não localizado.

8. Validação do Sistema e Bateria de Testes Automatizados

Para a homologação do sistema de orçamentação e comprovação de sua resiliência, a solução foi submetida à bateria oficial de testes integrada à aplicação frontend desenvolvida em Streamlit. A tabela abaixo resume os cenários validados e os comportamentos esperados mapeados de acordo com o caderno de testes da avaliação:

Caso	Cenário de Teste	Entrada do Cliente (Solicitação)	Status Esperado
01	Nome Comercial	Preciso de 3 unidades de ACCUVIT.	200 (Sucesso)
02	Código SAP	Favor cotar 5 unidades do código 1003649.	200 (Sucesso)
03	Princípio Ativo e Dosagem	Gostaria de orçamento para 2 unidades de acetilcisteína 40mg xarope.	200 (Sucesso)
04	Erro de Digitação	Quero 4 unidades de acetilsisteina 20mg.	200 (Sucesso)
05	Apresentação Específica	Me envie orçamento de 6 unidades de Acheflan creme bisnaga de 30g.	200 (Sucesso)
06	Múltiplos Itens	Preciso cotar: 2 un ACICLOVIR 200MG, 3 un creme 50mg, 1 un	200 (Sucesso)

ACHEFLAN aerosol

07	Mix Código e Texto	Cotar 2 unidades do código 1005119 e 3 unidades de ácido mefenâmico 500mg.	200 (Sucesso)
08	Pedido Informal/Linguagem Natural	Oi, consegue ver pra mim 10 caixas daquele remédio de herpes, aciclovir comprimido?	200 (Sucesso)
09	Produto Ambíguo	Preciso de 5 unidades de ACEBROFILINA.	422 (Unprocessable)
10	Produto Fora da Base	Preciso de 2 unidades de miojo.	404 (Not Found)
11	Falha - Payload Vazio	[String Vazia / Campo Ausente]	500 (Internal Error)
12	Falha - Sem Produto	'cotar'	500 (Internal Error)

8.1. Evidências de Execução da API (Screenshots)

[ESPAÇO RESERVADO: Cole aqui os prints de tela capturados da interface do Streamlit comprovando a execução com sucesso e a validação em verde (☑ Passou) de cada um dos 10 casos de teste oficiais da banca examinadora e dos 2 testes de estresse adicionais.]

9. Guia de Implantação e Execução Passo a Passo

9.1. Criação de Contas e Obtenção de Chaves de API

- **Qdrant Cloud (Banco Vetorial):** Acesse o painel da Qdrant Cloud, crie uma conta gratuita e inicialize um cluster (Free Tier). Copie a URL do endpoint da API (ex: <https://...aws.cloud.qdrant.io>) e gere uma API Key de acesso.
- **OpenRouter (Modelos LLM):** Crie uma conta no OpenRouter. Acesse a área de chaves de API (Keys), gere um novo token de acesso e certifique-se de que possui acesso ao modelo gratuito configurado (google/gemma-4-31b-it:free).

- **Hugging Face (Embeddings):** Crie uma conta no Hugging Face, navegue até as configurações do seu perfil (Settings -> Access Tokens) e gere um token com permissão de leitura (Read) para autenticar as chamadas da Inference API.

9.2. Importação dos Fluxos e Estrutura no n8n

Com a sua instância do n8n ativa, realize o deploy dos fluxos utilizando os arquivos JSON fornecidos:

1. **Fluxo de Ingestão:** Crie um novo workflow no n8n. No canto superior direito, clique no menu de três pontos, selecione 'Import from file' e escolha o arquivo 'AP2 - Chunking.json'.
2. **Fluxo de Consulta:** Repita o procedimento criando um segundo workflow independente e importando o arquivo 'AP2 - Consulta.json'.

9.3. Configuração de Credenciais Globais

Para que os nós consigam se comunicar com os ecossistemas externos, configure as credenciais no menu lateral esquerdo do n8n (Botão Adicionar -> New Credential):

- **Qdrant API:** Selecione o tipo **Qdrant API**. Preencha o campo de URL com o endpoint obtido e insira a API Key.
- **Qdrant Header Auth (HTTP Request):** Como o fluxo realiza chamadas diretas via requisição HTTP para a API Scroll e para os nós de criação/deleção de coleções, crie uma credencial do tipo **Header Auth**. Defina o nome do Header como 'api-key' e insira a mesma API Key da conta Qdrant como valor.
- **Hugging Face API:** Selecione a credencial do Hugging Face e insira o Access Token gerado no seu perfil.
- **OpenRouter API:** Selecione o tipo correspondente à API do OpenRouter e vincule o seu token gerado.

9.4. Execução e Carga Inicial da Base Vetorial

Abra o fluxo **AP2 – Chunking** e clique em **Execute workflow**. O nó **Form enviar CSV** abrirá um formulário interno de upload. Selecione o arquivo **Catalogo-Produtos.csv** e envie. O pipeline irá deletar coleções antigas obsoletas, criará a nova estrutura indexada de 384 dimensões no Qdrant e populará os vetores de nomes e princípios ativos com os metadados fiscais automaticamente.

Nota: caso queira mudar o modelo usado para embeddings, altere o nó **Criar Colecao Qdrant**, colocando no campo "size" do JSON o tamanho de vetor do novo modelo que será usado.

9.5. Ativação da API de Produção para os Testes

1. Abra o fluxo **AP2 - Consulta**, salve as alterações e clique em **Publish**. Acesse as propriedades do nó inicial **Receber Solicitacao** (Webhook) e copie a URL contida na aba **Production URL**.
2. Baixe as dependências do arquivo de testes Python usando o comando **pip install streamlit requests**.
3. Rode o código do arquivo **testar_n8n.py** usando o comando **streamlit run testar_n8n.py** no terminal,
4. Insira a URL de produção na barra lateral do frontend em Streamlit e execute a bateria de testes automatizados para validar a entrega, ou execute testes manualmente na aba de testes manuais.